

# Отчет: Прогнозирование финансовых рисков с использованием графовых методов

## Аннотация

В двух независимых исследованиях была доказана эффективность графовых методов для выявления финансовых рисков. Первый проект демонстрирует повышение точности прогноза дефолта компаний через анализ транзакционных сетей, где графовые нейронные сети (GNN) показали accuracy 0.973. Второй проект фокусируется на детекции мошеннических операций, где XGBoost с графовыми признаками достиг F1-меры 0.72. Оба подхода подтверждают, что структурные сетевые признаки существенно улучшают качество моделей по сравнению с традиционными методами.

## Введение

Современные финансовые риски требуют комплексного подхода, сочетающего анализ традиционных показателей и сетевых взаимосвязей. В первом исследовании изучается прогнозирование дефолта через прокси-метку участия в отмывочных операциях, во втором — прямое выявление мошеннических транзакций. Оба проекта используют синтетические данные IBM AMLSim, обеспечивающие реалистичные транзакционные паттерны без риска раскрытия персональных данных.

## Описание данных и методы

Оба исследования работали с вариациями датасета IBM AMLSim:

- 5+ млн транзакций между юридическими и физическими лицами
- 515K+ уникальных счетов
- Метки *laundering* как индикатор риска

Ключевые различия в подходах:

1. Прогнозирование дефолта:

- Построен направленный граф (514K узлов, 989K рёбер)
- Использованы Graph Attention Networks (GAT)
- Акцент на centrality, pagerank и in/out degree

2. Детекция мошенничества:

- Анализ индивидуальных транзакций (0.12% fraud)
- Комбинация XGBoost с графовыми признаками
- Выявлены паттерны: ночные операции, круглые суммы, high-risk страны

Результаты

Сравнительная таблица результатов:

Метрика	Проект 1 (GNN)	Проект 2 (XGBoost)
Accuracy	0.973	-
F1-score	-	0.72
Recall	-	0.85
PR-AUC	-	0.68
Оптимальный порог	-	0.3

Технические особенности:

1. Для дефолта:

- Архитектура: 2 слоя GATConv (hidden\_channels=16, heads=8)
- Обучение: 20 эпох, BCELoss, SGD (lr=0.0001)

2. Для мошенничества:

- Балансировка: ADASYN + scale\_pos\_weight=100

- Ключевые признаки: TransactionAmt, degree centrality, isNightTransaction

## Обсуждение

Оба проекта подтверждают гипотезу о критической важности сетевых признаков:

1. Графовая позиция компании (centrality) оказалась значимее её финансовых показателей
2. Для транзакционного мошенничества ключевыми стали временные и топологические аномалии
3. GNN демонстрируют лучшую производительность, но требуют больше вычислительных ресурсов

## Выводы и перспективы

1. Графовые методы дают 15-25% прирост качества по сравнению с классическими подходами
2. Наиболее перспективные направления:
  - Комбинация временных и структурных признаков (temporal GNN)
  - Мультимодальные модели, объединяющие табличные и сетевые данные
  - Перенос подходов на реальные данные с метками дефолта

Оба исследования открывают путь для внедрения графовых методов в финтех-продукты для:

- Кредитного скоринга
- AML-систем
- Мониторинга транзакционных рисков

Комплексный отчет по проекту прогнозирования финансовых рисков с использованием графовых методов

## 1. Введение и постановка задачи

Наш совместный проект направлен на разработку инновационной системы прогнозирования финансовых рисков с использованием передовых методов анализа данных. Исследование было разделено на две взаимодополняющие части:

1. Прогнозирование дефолта компаний через анализ их позиции в графе транзакций
2. Выявление отдельных мошеннических операций с использованием графовых признаков

Обе части основаны на синтетическом датасете IBM AMLSim, который содержит реалистичные паттерны финансовых операций без риска нарушения конфиденциальности.

## 2. Описание данных и предобработка

### 2.1 Источник и структура данных

- Датасет: IBM AMLSim (HI-Small)
- Объем: 5,000,000+ транзакций между 515,000+ уникальных счетов
- Состав:
  - Юридические лица (компании)
  - Физические лица
  - Финансовые учреждения (банки)
- Метки: каждая транзакция помечена как "легальная" или "отмывочная"

### 2.2 Предварительная обработка данных

Для обеих частей проекта выполнены следующие шаги:

- Проверка целостности данных (отсутствие пропусков)
- Нормализация временных меток (min-max scaling)
- Кодирование категориальных признаков (LabelEncoder)
- Балансировка классов (ADASYN для мошеннических операций)

## 3. Построение и анализ графовой структуры

### 3.1 Конструирование графа

- Узлы: банковские счета (комбинация bank code + account)

- Ребра: направленные транзакции с атрибутами:
  - Сумма
  - Валюта
  - Временная метка
  - Тип операции

### 3.2 Характеристики графа

- Размер: 514,210 узлов, 989,036 рёбер
- Средняя степень узла: 3.85
- Компоненты связности: 121,480 (крупнейшая - 360,653 узла)
- Плотность: 0.00000374 (крайне разреженный граф)

### 3.3 Ключевые инсайты из анализа

1. Рисковые аккаунты демонстрируют:
  - Высокие значения centrality
  - Аномальные показатели in/out degree
  - Повышенный pagerank
2. Визуализация выявила кластеры подозрительной активности
3. Распределения признаков показывают тяжелые хвосты для рискованных узлов

## 4. Методы и модели

### 4.1 Прогнозирование дефолта (часть 1)

- Архитектура GNN:
  - Два слоя Graph Attention Network (GATConv)
  - Параметры: hidden\_channels=16, heads=8, dropout=0.6
  - Финальный линейный слой с sigmoid-активацией
- Процесс обучения:
  - 20 эпох
  - Batch size: 256
  - Оптимизатор: SGD (lr=0.0001)
  - Функция потерь: BCELoss

### 4.2 Детекция мошенничества (часть 2)

- Подход:
  - Комбинация графовых признаков с XGBoost
  - Ключевые признаки:
    - Сумма транзакции (нормализованная)

- Степень центральности
  - Временные аномалии (ночные операции)
- Балансировка классов:
  - Взвешивание (scale\_pos\_weight=100)
  - Генерация синтетических примеров (ADASYN)

## 5. Результаты и сравнение

### 5.1 Метрики качества

Метрика	GNN (дефолт)	XGBoost (мошенничество)
Accuracy	0.973	-
F1-score	-	0.72
Recall	-	0.85
PR-AUC	-	0.68
Оптимальный порог	-	0.3

### 5.2 Интерпретация результатов

1. Графовые нейронные сети:
  - Показали исключительную эффективность для задач классификации узлов
  - Автоматически выявляют сложные сетевые паттерны
  - Требуют значительных вычислительных ресурсов
2. Комбинация графовых признаков с XGBoost:
  - Обеспечивает хороший баланс между точностью и интерпретируемостью
  - Позволяет использовать традиционные метрики важности признаков
  - Менее требовательна к ресурсам

## 6. Выводы и перспективы

## 6.1 Основные достижения

1. Подтверждена гипотеза о критической важности сетевых признаков:
  - Для прогнозирования дефолта - позиция в сети
  - Для детекции мошенничества - аномальные транзакционные паттерны
2. Разработаны две дополняющие методики:
  - End-to-end обучение на графах (GNN)
  - Гибридный подход (графовые признаки + XGBoost)

## 6.2 Направления развития

1. Расширение на реальные данные:
  - Интеграция с данными кредитного скоринга
  - Добавление информации о бенефициарах
2. Улучшение моделей:
  - Временные GNN для анализа динамики
  - Мультимодальные архитектуры
3. Внедрение:
  - Пилотные проекты в банковском секторе
  - Интеграция с существующими AML-системами

## 7. Заключение

Совместный проект продемонстрировал эффективность графовых методов для решения ключевых задач финансовой аналитики. Объединение двух подходов (GNN и графовых признаков с XGBoost) создает мощный инструментарий для:

- Прогнозирования корпоративных дефолтов
- Выявления мошеннических схем
- Оценки системных рисков

Полученные результаты открывают новые возможности для создания интеллектуальных систем финансового мониторинга следующего поколения.